

[System Init] MDP_Environment_Loaded

超越規則：深度強化學 學習重塑量化交易大腦

從特徵感知、動態整合到多智能體生態
系統的進化藍圖




傳統量化交易



- › 靜態規則 (Static Rules)
- › 雜訊過度擬合 (Noise Overfitting)
- › 無法適應非平穩市場 (Non-stationary Markets)

深度強化學習 (DRL)



- › 動態適應 (Dynamic Adaptation)
- › 延遲獎勵最佳化 (Delayed Reward Optimization)
- › 連續決策能力 (Continuous Decisions)

將市場視為馬可夫決策過程 (MDP)

1. 狀態 (State)

價格 (Price) / 指標 (Indicators) / 持倉 (Positions)

2. 行動 (Action)

買 (Buy) / 賣 (Sell) / 持有 (Hold)

3. 獎勵 (Reward)

資產變化 (PnL - Profit and Loss)

證據卡片一：FinRL 的壓倒性優勢 (Dow Jones 30)

Cumulative Return with Transaction Cost



分析結論：集成策略（Ensemble Strategy）的夏普比率高達 1.30，遠超 DJIA 的 0.47。在年化波動率大幅降低的同時，實現了顯著的風險調整後報酬領先。

證據卡片二：StockMARL 的穩健表現



分析結論：透過觀察其他交易者的行為，DQN RL 代理人學會了避免頻繁的無效交易，在 S&P 500 測試子集中實現了穩定且高達 **12.2%** 的年化報酬率，展現出強大的長期投資紀律。

證據卡片三：巴西市場 SAC 演算法的極限風險控制



4.2

SAC 代理人夏普比率 (Sharpe Ratio)

1.3

基準 (IBOVESPA) 夏普比率

3.8% vs 21.2%

SAC 年化波動率 vs 大盤波動率

分析結論：在高度波動的巴西市場 (WIN與WDO合約測試) 中，Soft Actor-Critic (SAC) 演算法展現了驚人的下檔保護能力。以極低的 3.8% 波動率，創造了高達 4.2 的夏普比率，徹底粉碎傳統大盤的風險回報邊界。

證據卡片四：台灣市場的本土對決 (SAC vs. 0050)

DRL 代理人 (SAC)

- **模型建構**：依據財報篩選成分股，並使用線上深度強化學習動態調整權重，每三個月汰弱留強。



報酬 (Return) 略優於大盤



風險 (Risk) 承擔略高

對比基準 (0050 ETF)

- **對比基準**：元大台灣卓越 50 (0050)，代表大盤穩定表現。



報酬 (Return) 基準表現




風險 (Risk) 基準表現

分析結論 (The Nuance)

DRL 在台股市場能有效獲取**超額報酬 (Alpha)**，但在動態權重調整的過程中，其**波動性控制**仍有優化空間，這突顯了「**特徵工程**」與「**風險懲罰函數設計**」的關鍵性。

證據卡片五：總經變數的邊際效應 (PPO2 實驗)




原因剖析 (Why?)

- 分析結論：加入總經指標並未讓模型的操作績效變得更好。
- 維度災難 (Curse of Dimensionality)：總經指標與單一股票短中期的價格變化、波動幅度缺乏高度相關性與敏感度的一致性。過多低關聯特徵反而稀釋了核心訊號，干擾了 RL 代理人的策略收斂。

重構市場數據：多維度視覺化空間

將非結構化金融數據轉化為神經網路影像張量



12 維特徵組合

5 種價格：

開盤, 最高, 最低, 收盤, 調整後收盤

7 種技術指標：

RSI, Momentum, PPO, Stochastic %K, Bollinger Bands, Fibonacci, MACD

AI 不讀枯燥的數字列表，而是將金融歷史重構為多通道的「市場熱圖影像」，使其具備視覺識別能力。


混合感知架構：CNN-LSTM-DQN

空間與時間特徵的雙軌萃取流水線




打開黑盒子：AI 決策的可解釋性 (Explainability)

空間顯著圖 (CNN Saliency Map)



CNN 梯度圖證明模型並非隨機讀取，而是精準鎖定矩陣中特定的技術指標排列模式。

時間注意力權重 (LSTM Attention Weights)



Bahdanau 注意力機制讓 LSTM 動態調整焦點，在關鍵時刻極度聚焦於最近期的市場事件與價格波動。

單一模型的脆弱性：非平穩市場的挑戰

為何我們需要整合型演算法？



結論：金融市場具備高度非平穩性。
解法為導入「整合型演算法策略 (Ensemble Strategy)」。

三大核心演算法的戰略矩陣 (Ensemble Matrix)


PPO (近端策略最佳化)	A2C (優勢演員-評論家)	DDPG (深度確定性策略梯度)
牛市趨勢追隨者	熊市防禦者	動態互補者
 特性 限制策略更新幅度	 特性 利用優勢函數降低變異數	 特性 直接映射連續動作空間
 表現 累積報酬最高 (83.0%)	 表現 年度波動率最低 (10.4%)， 最大回撤極小 (-10.2%)	 表現 適應特定波動區間
 角色定位 牛市攻擊主力	 角色定位 熊市下檔保護	 角色定位 輔助與穩定劑

動態輪替機制：透過夏普值 (Sharpe Ratio) 動態評估，選出當下最適合的演算法。
整合策略最終以 1.30 的夏普值，大幅擊敗大盤。

動態適應：滾動時間軸訓練機制 (Rolling Window)



每三個月重新輪替，確保 AI 大腦永遠貼合最新市場 Regime (Market State)。



極端風險阻斷：亂流指數 (Turbulence Index)



應對黑天鵝事件的物理防禦機制



計算總體經濟亂流指數
(馬哈拉諾比斯距離)

亂流指數
> 閾值?



觸發紅色警報：
強制阻斷買入，
啟動一鍵全面清倉
(Sell All)



安全狀態：
恢復 AI 自主
交易

數據推正確的歷史找實-2020




環境進化：從死板數據到擬真市場



為何我們需要多智能體強化學習 (MARL)？

靜態歷史數據的侷限



死板的歷史回測缺乏市場流動性變化，且無法反映真實市場中交易者互相博弈的真實反饋。容易陷入單機解謎的過度擬合。

VS

生成式多智能體擬真市場 (StockMARL)



構建一個由異質交易員組成的活體金融生態系。AI 不僅看懂線圖，更透過『觀察』其他交易者的行為來進化，如同進入多人連線的生存遊戲。



StockMARL 交易生態系地圖

6 種對手盤交織的真實市場叢林



核心價值：強化學習智能體在充滿雜訊與博弈的環境中，學會適應不同風格的對手，大幅提升實戰生存率。

總體經濟指標的宏觀視角與維度詛咒



數據擴充：導入宏觀視野



宏觀悖論 (The Macro Paradox) 實驗反思

無總經指標
(Dataset 1)



有總經指標
(Dataset 2)



警示：維度詛咒與敏感度落差

盲目加入總經指標反而導致報酬下降 6.06%。因個股對總經指標的延遲反應不一，直接融合會干擾決策。未來需搭配特製卷積架構 (如 CnnLstmPolicy) 來獨立處理不同頻率的特徵。

形塑 AI 行為的終極準則：獎勵函數設計

AI 的品格來自於你如何獎勵與懲罰它



正向增益區 (Performance Rewards)

短期戰術：日報酬率 (Daily MWRR)、勝率、單筆利潤

長期戰略：累積總報酬

風險調整：夏普值 (Sharpe Ratio)

負向懲罰區 (Constraint Costs)

集中度懲罰：防止持倉過度重押單一資產

波動懲罰：抑制無意義的頻繁過度交易


物理限制：無效動作懲罰 (空倉賣出)、流動性懲罰

透過非線性的雙向獎懲機制，迫使 AI 在『激進追高』與『保守保本』之間，精準計算出完美的數學平衡點。

終極量化大腦：次世代交易引擎完整藍圖




混合感知層 (Hybrid Perception)



9x9x12 CNN-LSTM 雙軌架構，提取空間訊號與時間序列，過濾雜訊。

動態決策層 (Ensemble Decision)



PPO / A2C / DDPG
滾動式競爭輪替，完美適應牛市與熊市轉換。

環境生態層 (MARL Ecosystem)



6 大擬真交易對手盤，提供真實博弈環境與流動性訓練。

宏觀風控層 (Macro & Risk Control)



亂流指數 (Turbulence)
強制阻斷黑天鵝，總體經濟指標提供宏觀視野。

終極交易終端

「AI 在金融的未來，不再是尋找那條神奇的均線，而是打造一個能感知、適應並在市場叢林中自我進化的活體大腦。」

參考資料

AI-Driven Regulation and Risk Control Mechanisms for High-Frequency Financial Trading. (2026). *Journal of Sustainability, Policy, and Practice*, 2(1), 185-194. <https://schoalrx.com/index.php/jspp/article/view/89>

Zhang, Hengxi & Shi, Zhendong & Hu, Yuanquan & Ding, Wenbo & Kuruoğlu, Ercan & Zhang, Xiao-Ping. (2024). Optimizing Trading Strategies in Quantitative Markets Using Multi-Agent Reinforcement Learning. 136-140. 10.1109/ICASSP48485.2024.10446489.

Yang, H., Liu, X. Y., Zhong, S., & Walid, A. (2020, October). Deep reinforcement learning for automated stock trading: An ensemble strategy. In *Proceedings of the first ACM international conference on AI in finance* (pp. 1-8).

de Cerqueira Silva, R., & Rodrigues, C. A. (2024). Optimizing Automated Trading Systems Portfolios with Reinforcement Learning for Risk Control. *JOURNAL OF BIOENGINEERING, TECHNOLOGIES AND HEALTH*, 7(Suppl2), 31-38.

Zou, P., & Siebers, P. O. (2025). StockMARL: A Novel Multi-Agent Reinforcement Learning System to Dynamically Improve Trading Strategies. *Procedia Computer Science*, 274, 929-938.

何祁栋. (2022). 结合趋势的深度强化学习股票交易策略. *Computer Science and Application*, 12, 673.